Challenge | Telecom X – Parte II

Definição do problema

A Telecom X é uma empresa de telecomunicações que oferece serviços de telefonia, provedor de internet (DSL e Fibra óptica) e serviços adicionais, além de streaming de filmes e TV a cabo.

A empresa tem enfrentado a saída de clientes, considerando que cerca de 30% da base de clientes não possui contrato ativo. De tal forma, a partir do uso de ferramentas nesta base de dados para poder prever a evasão de clientes e tentar responder as questões formuladas:

1. Quem são os clientes com maior risco de evasão?
2. Quais são as variáveis mais influenciam esse comportamento?
3. Que tipo de perfil a empresa precisa manter mais próximo?

Para responder a estas questões, precisamos dados sobre o perfil do consumidor, o perfil os serviços contratados, o perfil contratual dos clientes consolidado na base de dados.

Coleta dos dados

Delimitado um problema e os atributos envolvidos, coletamos os dados originados da análise da fase anterior. Foi disponibilizada uma base de dados de clientes com 7043 observações e 22 colunas:

id_cliente	multiplas_linhas	tipo_contrato
cliente_ativo	provedor_internet	fatura_digital
genero	seguranca_online	meio_pagamento
cliente_idoso	backup_online	fatura_mensal
cliente_parceiro	protecao_dispositivo	custo_total
cliente_dependentes	suporte_tecnico	contas_diarias
meses_contrato	streaming_TV	
linha_telefonica	streaming_filmes	

Tratamento da base de dados

coluna **'id_cliente'**	A coluna 'id_cliente' tem sentido no cadastro do cliente para sua identificação. Para a criação de um modelo preditivo deve ser removida dos dados de entrada (features/atributos) para garantir que o modelo aprenda padrões gerais e não decore dados históricos. Por isso, vamos remover a coluna.
Variáveis categóricas rotuladas com **Sim** e **Não**	No conjunto de dados, temos muitas variáveis categóricas, tais como 'cliente_idoso', 'backup_online' que utilizam o rótulo 'Sim' ou 'Não'. Nestes casos, vamos fazer a substituição direta com a função *map*: **Sim --> 1** **Não --> 0** Os algoritmos, em geral, trabalham melhor com números e isso facilitará o processamento.
coluna **'genero'**	A variável gênero do cliente recebe como categorias 'Feminino' e 'Masculino'. Podemos aplicar o *encoding*, que criará duas variáveis: 'genero_feminino' e 'genero_masculino'. No entanto, isto é uma redundância e pode gerar, multicolinearidade perfeita. De tal forma, utilizamos apenas uma variável dummy **'genero_feminino',** onde: **Feminino --> 1** **Masculino --> 0** Após, a variável **'genero'** foi excluída.

	cliente_ativo	genero
0	1	Feminino
1	1	Masculino
2	0	Masculino
3	0	Masculino

genero_feminino
1
0
0
0

colunas **'backup_online'** **'protecao_dispositivo'** **'suporte_tecnico'** **'seguranca_online'**	Neste caso, as colunas tornaram-se binárias e fizemos o agrupamento dos serviços na coluna **'servicos_internet_adicionais'** Com isto, temos a contagem de serviços contratados (0 a 4). Ademais, é uma forma de reduzir o número de colunas com a preservação da informação. Foram excluídas as colunas originais

	backup_online	protecao_dispositivo	suporte_tecnico	seguranca_online
0	1	0	1	0
1	0	0	0	0
2	0	1	0	0
3	1	1	0	0
4	0	0	1	0

colunas **streaming_TV' 'streaming_filmes'**	Neste caso, à exemplo do tratamento anterior, as colunas tornaram-se binárias e fizemos o agrupamento dos serviços na coluna **'servicos_streaming'** Com isto, temos a contagem de serviços contratados (0 a 2). Foram excluídas as colunas originais

streaming_TV	streaming_filmes
1	0
0	1
0	0
1	1
1	0

	servicos_streaming	servicos_internet_adicionais
0	1	2
1	1	0
2	0	1
3	2	2
4	1	1

coluna **'meio_pagamento'**	A variável contém 4 categorias: 1. Cheque eletrônico 2. Cheque via correio 3. Transferência bancária (automático) 4. Cartão de crédito (automático) Conseguimos abstrair e visualizar que temos duas formas de pagamento: • itens 1 e 2: forma de pagamento manual • itens 3 e 4: forma de pagamento automático Assim como a variável 'genero', formulamos a variável binária **'pagamento_manual'** em que: **Manual --> 1 Não manual (Automático) --> 0** A partir disso, excluímos a coluna **'meio_pagamento'**

	meio_pagamento
0	Cheque via correio
1	Cheque via correio
2	Cheque eletrônico
3	Cheque eletrônico
4	Cheque via correio

	pagamento_manual
0	1
1	1
2	1
3	1
4	1

colunas **'fatura_mensal'** **'custo_total'**/ **'contas_diarias'**	**'fatura_mensal'**: é o custo recorrente atual e captura o peso financeiro mensal de cada cliente. É um atributo que costuma ter relação direta com a evasão: quanto maior a fatura, maior a chance de evasão, que não é linear. **'custo_total'** é um valor acumulado histórico e depende de *'meses_contrato'* e *'fatura_mensal'*. Por isso, carrega em si informação redundante, uma vez que: custo_total ≈ fatura_mensal × meses_contrato **'contas_diarias'** é o custo normalizado no tempo. É como uma fatura diária, visto que é a relação de 'fatura_mensal' / dias(mês) Feitas estas considerações, avaliamos que os três atributos apresentam o mesmo tipo de informação, o que pode implicar em alta correlação entre elas. Por isso, vamos manter apenas **'fatura_mensal'**, excluindo **'custo_total'** e **'contas_diarias'**.

Todas estas mudanças visaram trazer variáveis mais significativas além de reduzir a dimensionalidade do conjunto de dados com a preservação da informação.

Encoding

Ainda restam dois atributos ('provedor_internet' e 'tipo_contrato') que precisam ser submetidas ao encoding.

Como opção, podemos utilizar o recurso get_dummies, função da biblioteca Pandas, ou o OneHotEncoder (OHE). Ambos tem resultado parecido, mas o OHE tem indicação para dados de entrada de algoritmos de Machine Learning, como o caso de predição.

Após realizar a operação, as colunas podem ser visualizadas no formato: prefixo 'onehotencoder' com 2 underscore/underline '__' seguida do nome da variável: 'onehotencoder__nome_da_variavel'

As variáveis que não sofreram o encoding, são visualizadas no formato: prefixo 'remainder' com 2 underscore/underline '__' seguida do nome da variável: 'remainder__nome_da_variavel'

Para prosseguirmos, as colunas foram renomeadas. Exemplo:

'onehotencoder__provedor_internet_DSL' → 'provedor_DSL'

Verificação da proporção de evasão

Com relação à proporção dos dados, 5174 são clientes ativos, ou 73,5%, e 1869 ou 26,5% evadiram.

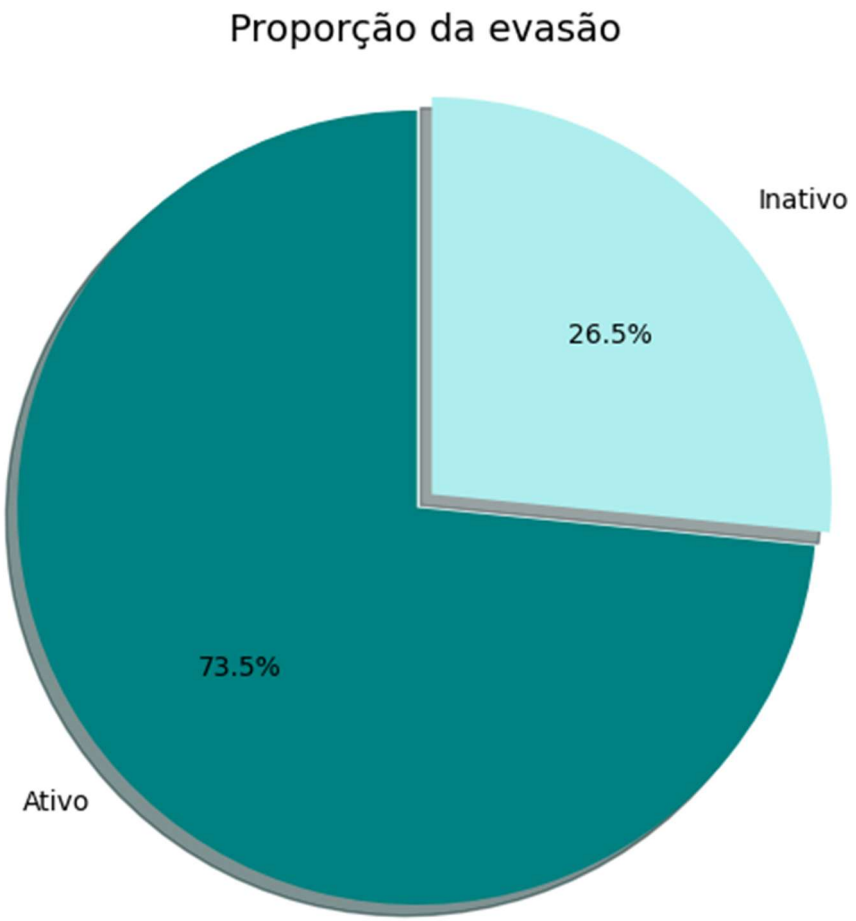

Balanceamento dos dados.

Considerando a proporção dos dados de evasão, tomamos a decisão de não realizar o balanceamento considerando que o desbalanceamento do conjunto de dados é moderado e pode representar a realidade do fenômeno.

Ademais, o balanceamento artificial através da introdução de dados sintéticos (SMOTE, etc) pode introduzir um viés.

Modelagem

Prosseguimos com a modelagem dos dados e, para isto, vamos separar os dados em dois grupos:

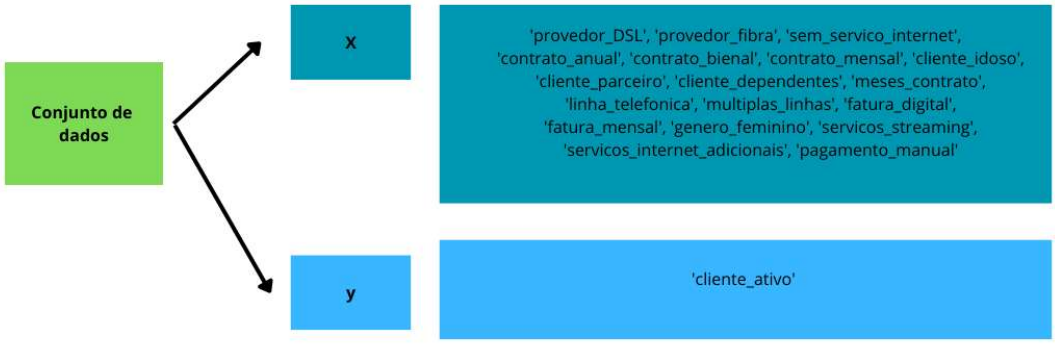

Onde X é a seleção dos atributos, features ou variáveis explicativas. E y é o agrupamento da variável alvo, target ou variável explicada.

- **Separação das bases de treino e teste**

Cada base foi separada em dados de treino e dados de teste, considerando 30% para teste e 70% para treino do modelo, utilizando o recurso *'train_test_split'*.

- **Criação de modelos.**

Baseline | DummyClassifier

O DummyClassifier foi utilizado como baseline para estabelecer um desempenho mínimo de referência. Modelos mais complexos devem superá-lo para serem considerados eficazes. Ele funciona como um "ponto de partida" ou "linha de base" para comparação.

Modelo | RandomForestClassifier

O Random Forest foi utilizado por sua capacidade de modelar relações não lineares e interações complexas entre variáveis, sendo adequado para conjuntos de dados heterogêneos. Este é um modelo que não exige normalização.

Modelo | LogisticRegression

A Regressão Logística foi escolhida por ser um modelo linear amplamente utilizado em classificação binária, oferecendo interpretabilidade dos coeficientes e servindo como referência para comparação com modelos não lineares. Por exigir normalização, foi aplicada a StandardScaler.

- **Avaliação dos modelos**

Cada modelo deveria ser avaliado utilizando as seguintes métricas: Acurácia, Precisão, Recall, F1-score e Matriz de confusão.

Precisamos fazer uma anotação: a acurácia pode ser enganosa em dados balanceados, ao contrário, a curva Roc (ROC-AUC) funciona bem com classes desbalanceadas como é

o caso do conjunto de dados. Por fim, a matriz de confusão nos fornecerá um panorama global.

	Modelo Baseline	RandomForestClassifier	LogisticRegression
Acurácia	0.73450	0.786600	0.8102
Precisão	0.73450	0.828700	0.8440
Recall	1.00000	0.894300	0.9098
F1-Score	0.84693	0.860242	0.8757
ROC-AUC	0.50000	0.831207	0.8560

- **DummyClassifier**

Verdadeiro Positivo **0**	Falso Negativo **561**
Falso Positivo **0**	Verdadeiro Negativo **1552**

Quanto à matriz de confusão, denotamos que o modelo prevê tudo como classe 1 e nenhuma previsão com classe 0.

Por serem iguais à proporção da classe majoritária, a acurácia e a precisão demonstram que o modelo não teve aprendizado, somente explorando o desbalanceamento.

O valor da ROC-AUC nos infirma que é um classificador aleatório sem a capacidade de separar as classes e sem poder preditivo.

- **RandomForestClassifier**

Verdadeiro Positivo **284**	Falso Negativo **277**
Falso Positivo **168**	Verdadeiro Negativo **1384**

Este algoritmo apresenta uma clara melhora, com ROC-AUC demonstrando que o modelo aprendeu padrões reais, com um ótimo equilíbrio entre precisão e recall.

A matriz de confusão mostra que o modelo aprendeu a prever a classe 0, que significa a evasão. Mesmo a acurácia já demonstra um aprendizado real.

- **LogisticRegression**

Verdadeiro Positivo **300**	Falso Negativo **261**
Falso Positivo **140**	Verdadeiro Negativo **1412**

Este modelo teve melhoria em todas as métricas. A acurácia representa um ganho real, com melhor precisão que RandomForest. F1-Score indica um modelo mais bem calibrado e a ROC-AUC como melhor métrica global apontando capacidade de separação muito boa.

A matriz de confusão apontou menos FN (falso negativo) e FP (falso positivo).

Embora o Random Forest tenha apresentado desempenho robusto e substancialmente superior ao baseline, a Regressão Logística obteve os melhores resultados globais, com maior ROC-AUC, F1-score e equilíbrio entre precisão e recall. Além disso, trata-se de um modelo mais simples, interpretável e estável, tornando-se a escolha mais adequada para o problema analisado.

- **Análise de variáveis**

Coeficientes da Regressão Logística

index	Variável	Coeficiente	Odds ratio
2	sem_servico_internet	0.993422708977019	2.700461566558225
4	contrato_bienal	0.9267293733189403	2.5262332853324723
9	meses_contrato	0.8559739907905395	2.3536657132540153
10	linha_telefonica	0.5404960968419253	1.7168583789698404
0	provedor_DSL	0.23925272952313736	1.2702995382153681
16	servicos_internet_adicionais	0.22553315375499622	1.2529905747703034
8	cliente_dependentes	0.14665186017599177	1.157950764073906
3	contrato_anual	0.09830143338172595	1.1032953050245244
7	cliente_parceiro	0.023286974119417277	1.0235602327004847
14	genero_feminino	-0.03141440620125726	0.9690738996203097
13	fatura_mensal	-0.03944863324652026	0.9613193325755502
6	cliente_idoso	-0.21197507625291123	0.8089848602492895
15	servicos_streaming	-0.22736626494034576	0.7966289515942925
17	pagamento_manual	-0.2980869541772353	0.7422367963517156
12	fatura_digital	-0.3228752273258592	0.7240641921574594
11	multiplas_linhas	-0.3655562389615364	0.6938106190267237
5	contrato_mensal	-0.49199500459521317	0.6114054200423421
1	provedor_fibra	-0.6996396363946991	0.49676428730945926

O que pode aumentar a evasão?

‘sem_servico_internet’: o cliente sem internet tem 2,7 vezes mais chances de evasão. O cliente pode perceber pouco valor pela falta do serviço ou que o serviço é incompleto.

‘contrato_bienal’: contratos longos reduzem a evasão. No entanto, pode ser um contrato ruim, que tenha uma alta multa de rescisão e não pelo valor percebido pelo cliente.

‘linha_telefonica’: ter apenas linha telefônica aumenta a evasão, assim como o cliente que não possui serviço de internet.

‘provedor_DSL’: pode indicar a evasão pela tecnologia inferior à fibra óptica.

‘servicos_internet_adicionais’: pode representar por custo que não tenha real valor agregado.

O que pode reduzir a evasão?

‘provedor_fibra’: pela qualidade do serviço.

‘cliente_idoso’: clientes mais engajados ou estáveis.

- **Correlação**

Spearman

	cliente_ativo
cliente_ativo	1.000000
meses_contrato	0.367062
contrato_bienal	0.302253
sem_servico_internet	0.227890
contrato_anual	0.177820
cliente_dependentes	0.164221
servicos_internet_adicionais	0.150922
cliente_parceiro	0.150448
provedor_DSL	0.124214
genero_feminino	-0.008612
linha_telefonica	-0.011942
multiplas_linhas	-0.040102
servicos_streaming	-0.075255
cliente_idoso	-0.150889
fatura_mensal	-0.184743
fatura_digital	-0.191825
pagamento_manual	-0.209902
provedor_fibra	-0.308020
contrato_mensal	-0.405103

Pearson

	cliente_ativo
cliente_ativo	1.000000
meses_contrato	0.352229
contrato_bienal	0.302253
sem_servico_internet	0.227890
contrato_anual	0.177820
servicos_internet_adicionais	0.173061
cliente_dependentes	0.164221
cliente_parceiro	0.150448
provedor_DSL	0.124214
genero_feminino	-0.008612
linha_telefonica	-0.011942
multiplas_linhas	-0.040102
servicos_streaming	-0.071162
cliente_idoso	-0.150889
fatura_digital	-0.191825
fatura_mensal	-0.193356
pagamento_manual	-0.209902
provedor_fibra	-0.308020
contrato_mensal	-0.405103

Lembrando que, correlação não significa causalidade e os números devem ser analisados à luz das regras de negócio.
Segundo os valores de correlação, o que tem navegado a favor da manutenção do cliente: ‘meses_contrato’, ‘contrato_bienal’. Do contrário, a evasão tem sido facilitada pelo ‘contrato_mensal’, ‘provedor_fibra’, ‘pagamento_manual’.

Seguem os gráficos de dispersão para as variáveis: ‘fatura_mensal’ e ‘meses_contrato’ em relação à evasão (‘cliente_ativo’): não temos uma situação tão heterogênea que possibilite uma clara separação, baseado na proporção dos dados.

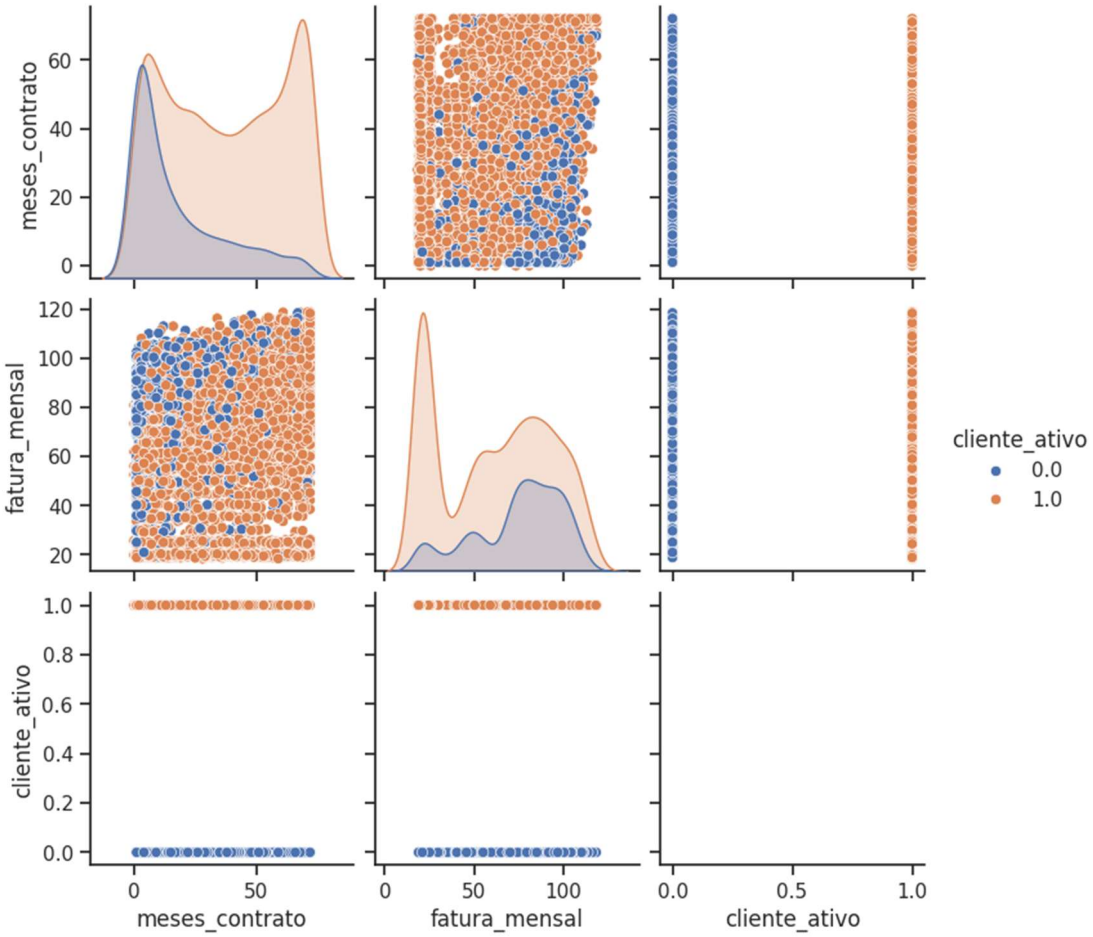

- **Lasso/RFE**

Importância das variáveis (Lasso)

meses_contrato	0.113805
servicos_internet_adicionais	0.061217
servicos_streaming	-0.000000
provedor_DSL	0.000000
contrato_bienal	0.000000
sem_servico_internet	0.000000
cliente_parceiro	0.000000
cliente_idoso	-0.000000
cliente_dependentes	0.000000
contrato_anual	0.000000
genero_feminino	-0.000000
linha_telefonica	0.000000
multiplas_linhas	-0.000000
pagamento_manual	-0.011670
provedor_fibra	-0.020319
fatura_digital	-0.024370
contrato_mensal	-0.093750
fatura_mensal	-0.120302

Variáveis selecionadas pelo RFE

Variáveis: 'provedor_fibra', 'contrato_mensal', 'meses_contrato', 'fatura_mensal', 'servicos_internet_adicionais'

Importância das variáveis com Random Forest

```
fatura_mensal                  0.282728
meses_contrato                 0.253370
contrato_mensal                0.070233
servicos_internet_adicionais   0.061781
provedor_fibra                 0.034900
genero_feminino                0.034670
servicos_streaming             0.034142
pagamento_manual               0.031948
fatura_digital                 0.030036
cliente_parceiro               0.028428
contrato_bienal                0.026018
cliente_dependentes            0.024607
cliente_idoso                  0.023717
multiplas_linhas               0.022428
sem_servico_internet           0.012439
contrato_anual                 0.010960
provedor_DSL                   0.010471
linha_telefonica               0.007124
```

A partir destas análises, foram selecionadas as seguintes variáveis:

'sem_servico_internet', 'provedor_fibra', 'provedor_DSL', 'linha_telefonica', 'meses_contrato', 'contrato_mensal', 'contrato_bienal', 'servicos_internet_adicionais', 'servicos_streaming', 'multiplas_linhas', 'fatura_digital', 'pagamento_manual', 'fatura_mensal', 'cliente_idoso'

	Modelo Baseline	RandomForestClassifier	RegressãoLogistica
Acurácia	0.73450	0.774300	0.8121
Precisão	0.73450	0.822400	0.8452
Recall	1.00000	0.883400	0.9111
F1-Score	0.84693	0.851817	0.8769
ROC-AUC	0.50000	0.822563	0.7247

A redução do conjunto de variáveis beneficiou o modelo Random Forest, mantendo desempenho com menor complexidade. Em contrapartida, a Regressão Logística apresentou perda significativa de poder discriminatório, evidenciada pela queda do ROC-AUC, indicando que o modelo linear depende de um conjunto mais amplo de variáveis para adequada separação dos clientes por risco de evasão.

A Random Forest ficou **mais simples e mais estável**, com **quase o mesmo poder preditivo**.

Regressão Logística perdeu com o conjunto de dados **reduzido**.

Matriz de confusão

RandomForestClassifier

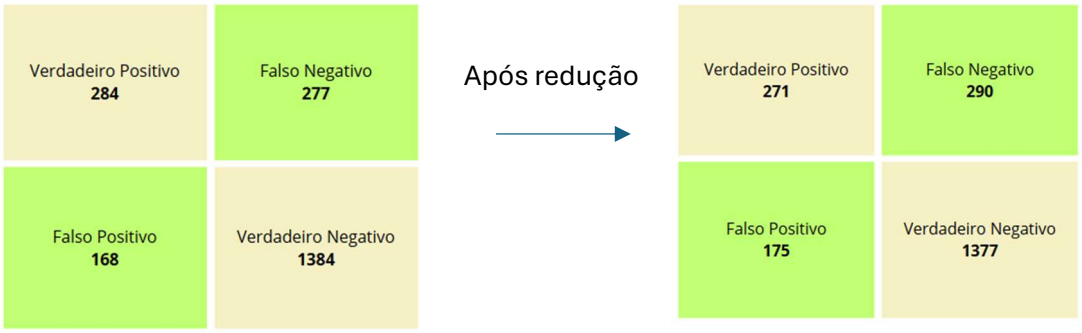

LogisticRegression

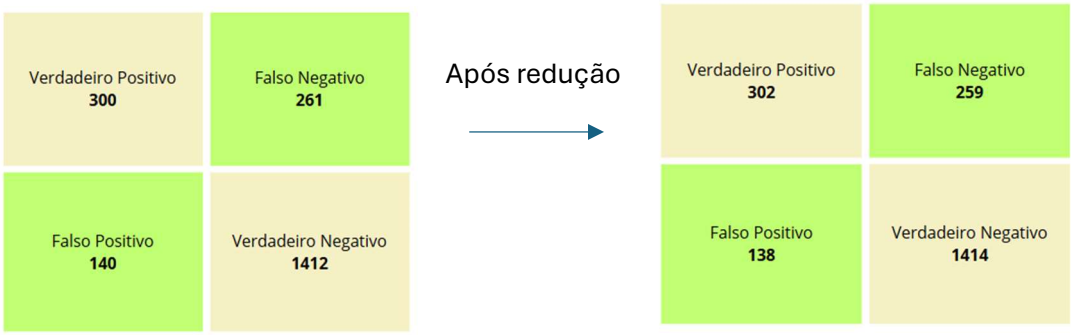

No intuito de ilustrar a utilização do classificador Random Forest, foram tomados como dados de entrada os dados excluídos na primeira fase: 224 registros que não estavam rotulados.

	Total de atributos		**Redução de atributos**	
Categoria	Quantidade	Percentual	Quantidade	Percentual
1 - Ativo	155	69,2	156	69,6
0 - Inativo	69	30,8	68	30,4

Denotamos que os valores, para ambos os formatos, são muito próximos.

Questões levantadas

1. Quem são os clientes com maior risco de evasão?

São clientes com baixo valor percebido, serviços limitados e tecnologias menos modernas: sem serviço de internet, tecnologia DSL, apenas uma linha telefônica, contrato pouco flexível, baixo engajamento com serviços adicionais, sem serviços de streaming.

2. Quais são as variáveis mais influenciam esse comportamento?
   - sem_servico_internet
   - meses_contrato
   - provedor_DSL
   - linha_telefonica
   - servicos_internet_adicionais

São fatores de proteção:

- provedor_fibra
- serviços_streaming
- fatura_digital

3. Que tipo de perfil a empresa precisa manter mais próximo?

A empresa deve manter acompanhamento **mais próximo e proativo** de clientes que:

- Estão há muito tempo na base
- Usam DSL ou não têm internet
- Possuem poucos serviços contratados
- Não utilizam recursos digitais
- Estão presos a contratos que não entregam valor percebido

O risco de evasão está fortemente associado a clientes com baixo engajamento, tecnologias defasadas e contratos que não entregam valor percebido ao longo do tempo. A empresa precisa concentrar esforços de retenção em clientes antigos com poucos serviços e infraestrutura inferior, enquanto perfis mais digitais e com fibra óptica demonstram maior estabilidade e menor propensão à evasão.